

Lógica e Inteligencia Artificial -

Práctica 7 - IA y Agentes

Inteligentes

Temario

- Agentes inteligentes. Racionalidad. REAS (Rendimiento, Entorno, Actuadores, Sensores). Tipos de entorno. Tipos de agentes. Agentes basados en conocimiento.
- Inteligencia artificial responsable.

Bibliografía

- Capítulos 1 y 2, Inteligencia artificial. Un enfoque moderno. Russell y Norvig.
- Alan Turing, 1950. Maquinaria computacional e Inteligencia.
- [Conferencia dictada por el Dr. Ricardo Baeza-Yates del Instituto de IA Experiencial de la Northeastern University, en USA, en las JAIIOs. Octubre 2022.](#)

Fecha de entrega

10 de noviembre de 2025.

Integrantes

- Lautaro Josin Saller
- Juan Cruz Cassera Botta
- Juan Cruz Mazullo
- Mariano Gonzalez

Ejercicios

1. Explique los siguientes conceptos
 - a. Inteligencia e Inteligencia Artificial

La inteligencia es la capacidad de un animal, humano o sistema de percibir o inferir información, y retenerla como conocimiento para aplicarlo a comportamientos adaptativos dentro de un entorno o contexto.

La Inteligencia Artificial, por otro lado, es la rama de las Ciencias de la Computación que se dedica al estudio y el desarrollo de los agentes racionales computacionales.

Un agente es cualquier cosa capaz de:

- Percibir su propio entorno, es decir recibir entradas.
- Procesar tales percepciones y actuar en consecuencia, es decir proporcionar salidas.

Que el agente sea racional implica que posee una capacidad de pensar y actuar conforme a principios de optimalidad y consistencia para alcanzar un objetivo determinado. Además, esta racionalidad está sujeta a mejora continua: el aprendizaje.

b. Diferencia entre IA débil e IA fuerte

La IA débil es la que busca emular solo algunas de las características de la inteligencia humana. Este tipo de IA existe y se usa en muchos sistemas reales para cumplir una tarea específica y no demasiado general, desde hace décadas.

La IA fuerte, por otro lado, es la que busca emular al 100% la inteligencia humana, en todos sus aspectos. Se asocia con la conciencia, la sensibilidad, la sapiencia y el auto-conocimiento. Este tipo de IA no existe actualmente, es puramente teórica.

c. Diferencia entre un sistema de IA y un sistema de software complejo (como el que calcula la trayectoria de un cohete a Marte)

Un sistema de software que no usa IA, por más complejo que sea, sigue una receta o algoritmo, para resolver un determinado problema.

Un sistema de IA, a diferencia, encuentra su propia forma de resolver el problema, forma que no fue programada de antemano por los desarrolladores.

d. Diferencia entre IA simbólica e IA no-simbólica

La IA simbólica es en la cual el programador conoce las reglas. Razonan por deducción.

La IA no-simbólica es en la cual el programador desconoce las reglas, pero tiene datos para que el sistema aprenda. Razonan por inducción. El campo más influyente en este tipo de IA es el Machine Learning.

2. Escuche la conferencia del Dr. Baeza-Yates y responda:

a. ¿Qué es la IA responsable?

La Inteligencia Artificial responsable es la práctica, idealmente, de desarrollar IAs que sean confiables, éticas y no sesgadas.

Se trata de hacer IAs que concuerden con los valores morales y éticos positivos de los seres humanos tales como la justicia, la transparencia, la inclusión y diversidad, etc. El ejemplo típico sería evitar todo tipo de sesgos discriminatorios en los datos que alimentan al modelo de IA.

Desarrollar IAs responsables es difícil, principalmente porque implica que nosotros mismos tenemos que ser conscientes de nuestros propios sesgos al desarrollar el modelo de IA.

b. ¿Cuáles son los problemas que plantea y cuáles son las posibles soluciones?

Los problemas que plantea el Dr. Baeza se resumen en dos: la IA irresponsable y la discriminación a partir de datos sesgados, un modelo de IA sesgado, y el sesgo entre la interacción entre la persona y el sistema. Es decir, que el sistema de IA discrimine o cause daños o perjuicios a parte de los usuarios por tratarlos de forma injusta, debido a cómo su modelo fue entrenado. El problema se agrava muchísimo más cuando estos sistemas de IA irresponsables se usan para tomar decisiones judiciales/legales que pueden afectar severamente la vida de muchísimas personas, a veces de forma permanente. También se dan ejemplos de automóviles inteligentes que causan accidentes y heridas o incluso la muerte a sus pasajeros.

Uno de los puntos claves que menciona Baeza es que no es necesario que el modelo sea 100% preciso y nunca se equivoque, si no que se tiene que tener mucho cuidado con qué nivel de impacto tienen los

errores que comete la IA: por ejemplo, falsos negativos pueden ser mucho peor que falsos positivos.

Otro punto clave que se menciona es que muchos modelos de IA irresponsables están entrenados para nunca responder con “no sé”, incluso si realmente no saben la respuesta a la pregunta que se les hizo, lo cual está mal, porque puede fácilmente engañar a los usuarios.

Finalmente, Yates habla del impacto ambiental/ecológico severo, así como el desperdicio enorme de recursos, que muchos sistemas irresponsables de IA tienen.

Las soluciones que se presentan a todos estos problemas son:

1. Regulaciones gubernamentales, como del gobierno de los Estados Unidos o la Unión Europea, imponiendo costos legales por romperlas.
2. Guías de estándares éticos internacionales sobre uso responsable de IA para organizaciones y empresas.

c. Da su opinión al respecto o describa un caso particular que conozcas donde alguno de estos problemas se haya presentado.

Uno de los casos más famosos fue el de Tay, en 2016. Tay fue un chatbot de inteligencia artificial publicado por Microsoft en marzo de 2016 que interactuaba en Twitter. Causó mucha controversia porque tan solo horas después de su publicación oficial comenzó a publicar tweets discriminatorios, ofensivos, racistas, etc, de forma totalmente desmedida, lo que provocó que Microsoft terminara el servicio del chatbot al día siguiente.

Lo que ocurrió fue que este chatbot aprendía de sus interacciones con los usuarios de Twitter, principalmente jóvenes, y muchos de éstos intencionalmente le “enseñaron” a hablar de formas muy ofensivas. Como el modelo no tenía filtros adecuados para no aprender de ideas extremistas o discriminatorias, simplemente “repetía” lo que estos usuarios le decían, sin ningún reparo en los posibles daños que podría causar.

El caso ilustra perfectamente por qué es tan importante que el modelo tenga filtros y controles adecuados sobre los datos a partir de los cuales aprende cosas, para que no termine siendo un sistema inmoral

y peligroso.

**3. Lea el artículo original de Turing sobre IA (Turing 1950).
Dónde comenta algunas objeciones potenciales a su
propuesta y a su prueba de inteligencia. ¿Cuáles de estas
objeciones tiene todavía validez? ¿Son válidas sus
refutaciones? ¿Se te ocurren nuevas objeciones a esta
propuesta teniendo en cuenta los desarrollos realizados
desde que se escribió el artículo?**

A lo largo del artículo de Turing, se describen múltiples objeciones a su propuesta o prueba de inteligencia, buscando responder la pregunta de **¿Las máquinas piensan?**. Algunas de estas objeciones, aunque bien refutadas por Turing en el artículo, creemos que todavía pueden tener validez, o incluso aumentar su relevancia, dada la situación actual con respecto al avance del desarrollo de la inteligencia artificial y su intromisión en la sociedad como nunca antes había sucedido.

- **El argumento de la conciencia propuesto por el profesor Jefferson y la incapacidad de creación de Lady Lovelace:**

El argumento sostiene que una máquina sólo podrá pensar cuando ésta sea capaz de escribir un soneto o componer un concierto en respuesta a pensamientos y emociones experimentadas.

En el artículo Turing refuta esta objeción, explicando que es una negación a la validez de su experimento y que es un argumento que lleva al solipsismo, es decir, para poder saber qué es ser un humano, tenés que ser humano, y que si una máquina puede responder de forma inteligente a preguntas acerca de un soneto y confundir a un evaluador dentro de la prueba, entonces el argumento es inválido.

Si bien creemos que el argumento de Turing tiene mucho sentido ya que bajo esas premisas, tiene poco sentido no solo hacer el experimento, sino plantear la pregunta disparadora de todo el artículo. Pero actualmente nos encontramos en una situación aún más extrema que la que Turing utiliza para refutar el artículo, ya no necesitamos pensar en una máquina siendo lo suficientemente inteligente como para responder de forma “audaz” las preguntas del juego. Nos vemos en la situación de máquinas capaces de crear la sonata o crear representaciones artísticas muy complejas.

Uno podría caer en la tentación de reafirmar las objeciones de Turing, solo

mostrando las capacidades de la inteligencia artificial de hoy en día. Pero consideramos completamente válida la discusión planteada por el profesor Jefferson, en seguir cuestionando la validez de esas representaciones artísticas, ¿Es arte lo que produce la IA hoy en día?, desde ya que no vamos a dar una respuesta a esta pregunta, pero sí nos vamos a permitir plantear un pequeño argumento para la negativa de este planteo. El arte puede pensarse no solo como la capacidad de poder interpretar un contexto (social, político, económico, etc) en una pintura, una canción, o en una filmografía, sino que existe una característica intrínseca en el arte que está en la disrupción artística. Con esto nos referimos a la capacidad humana de crear nuevas estructuras en la representación del arte como así nuevas formas de mostrar el mismo, capacidad que la máquina actual no posee, y uno podría pensar en que nunca la tendrá. Es decir la máquina no podría tomar una postura “vanguardista” del arte, y esto nos da una capacidad que la máquina no posee, mientras que el humano sí. Podríamos también entonces sumar la postura de Lady Lovelace que plantea justamente que la máquina no pretende crear nada, y sumarla como una objeción no solo válida sino vigente de la postura de Turing.


Por lo tanto, es posible formular una objeción contemporánea que profundiza el planteo de Turing, sintetizando la Objeción de Lady Lovelace y el Argumento de la Conciencia del Prof. Jefferson. Se concluye que la máquina no es capaz de "pensar" en el sentido humano, precisamente porque carece de la capacidad de objetar estructuralmente su propio mecanismo de razonamiento.

Mientras que un humano puede **alterar** sus reglas de conducta (como se explora en el Argumento de la Informalidad del Comportamiento), la máquina solo puede generar una "salida" estadísticamente óptima dentro de las reglas de su arquitectura. No puede permitirse objetar su propio mecanismo y adoptar una postura "vanguardista" que rompa con su entrenamiento. Esta objeción no solo sigue validando a Lady Lovelace, sino que también refuta la principal esperanza del propio Turing sobre las máquinas que aprenden. Aun siendo "máquinas que aprenden", los sistemas actuales demuestran que la objeción de Lovelace sigue vigente: no originan, sino que recombinan, careciendo de la autoconciencia necesaria para modificar su propia estructura de pensamiento en función de sus conclusiones.

- 4. Defina los siguientes términos: agente, función de agente, programa de agente, racionalidad, autonomía, agente reactivo, agente basado en modelo, agente basado en objetivo, agente basado en utilidad, agente que aprende.**

- **Agente:** Es una entidad que puede percibir su entorno mediante sensores y actuar sobre dicho entorno a través de actuadores.
- **Función de Agente:** Es la función que mapea las historias (secuencias) de percepciones a las acciones. Un agente está completamente especificado por esta función.
- **Programa de Agente:** Es el programa que se ejecuta sobre una arquitectura física para implementar la función del agente. La combinación de la arquitectura más el programa constituyen el agente.
- **Racionalidad:** Un agente racional es aquel que, para cada posible secuencia de percepciones, selecciona una acción que se espera que maximice su medida de desempeño. Esto se basa en la evidencia que proporcionan las percepciones y cualquier conocimiento que el agente tenga incorporado.
- **Autonomía:** Un agente es autónomo si su comportamiento está determinado por su propia experiencia, lo que le da la capacidad de aprender y adaptarse.
- **Agente Reactivo (Simple):** Es un agente que selecciona sus acciones basándose únicamente en las percepciones actuales, ignorando el resto del historial de percepciones.
- **Agente Basado en Modelo:** Es un agente que determina sus acciones no solo a partir de la percepción actual, sino que también tiene en cuenta el estado actual del mundo, cómo evoluciona este y los efectos que causan sus propias acciones.
- **Agente Basado en Objetivo:** Este agente considera lo que sucederá si realiza una acción (como el basado en modelo), pero además se pregunta si esa acción lo acercará a cumplir su meta o objetivo determinado.
- **Agente Basado en Utilidad:** Se utiliza cuando más de una secuencia de acciones puede llevar a la meta. Estos agentes evalúan la probabilidad de que una secuencia sea más útil que otra (por ejemplo, más rápida, segura o eficiente) y seleccionan la mejor.
- **Agente que Aprende:** Es un agente que puede mejorar su eficacia con la ayuda de mecanismos de aprendizaje. Se compone de cuatro elementos principales:
 - **Elemento de actuación:** Selecciona las acciones.
 - **Elemento de aprendizaje:** Modifica al elemento de actuación.
 - **Crítica:** Realimenta al elemento de aprendizaje sobre la actuación del agente.
 - **Generador de problemas:** Sugiere acciones para ganar nuevas experiencias.

5. Defina una función que determine la medida de rendimiento para el ambiente de la aspiradora descrito en la figura 2.2 del libro “Inteligencia Artificial” que se muestra abajo:



Este contexto tiene varios puntos relevantes para determinar el rendimiento:

- El estado de las cuadrículas a lo largo del tiempo. Es deseable que se mantengan limpias el mayor tiempo posible.
- La cantidad de movimientos hechos por la aspiradora, siendo deseable que use la menor cantidad de movimientos posibles para la limpieza.

En la función, por cada unidad de tiempo transcurrida, por cada baldosa que se encuentre limpia, se suma 5 puntos. Cada movimiento necesario para la aspiradora, resta 1 punto. Con esta función, se busca beneficiar al agente que mantenga la mayor cantidad de celdas limpias con la menor cantidad de movimientos.

6. Examine ahora la racionalidad de las siguientes funciones de agentes aspiradora.

- a. Muestre que la función de agente aspiradora descrita en la Fig.2.3 es realmente racional bajo la hipótesis presentada en la sección 2.2 Buen Comportamiento.**

La función es racional ya que el agente constantemente se mueve de recuadro a recuadro, limpiando los que estén sucios, y como la medida de rendimiento premia al agente con un punto por cada cuadrícula limpia en cada período de tiempo, entonces el agente siempre obtendrá puntos, maximizando su rendimiento (a pesar de ser ineficiente con la cantidad de movimientos utilizados).

- b. Describa una función para un agente racional cuya medida de rendimiento modificada deduzca un punto para cada movimiento. ¿Requiere el programa de agente**

estado interno?

El agente requiere un estado interno para guardar el tiempo necesario de espera. Este tiempo de espera se incrementa cuando la baldosa está limpia y el agente no aspiró recién, o sea, que no pasó suficiente tiempo para que se haya ensuciado, por lo tanto desperdició un movimiento.

funcion agente-mas-eficiente([localizacion, estado]) **devuelve** una acción

estático: *tiempo*, tiempo que espera para volver a chequear, inicialmente 0
recién_aspirado, booleano que permite conocer si la aspiradora aspiró recientemente la localización en la que está

```
si estado = Sucio entonces recién_aspiré = True, tiempo=0 y devolver Aspirar
```

```
si no, si localizacion = A y recién_aspiré = True entonces recién_aspiré =  
False, esperar(tiempo) y devolver Derecha
```

```
si no, si localizacion = B y recién_aspiré = True entonces recién_aspiré =  
False, esperar(tiempo) y devolver Izquierda
```

```
si no, si localizacion = A y recién_aspiré = False entonces  
incrementar(tiempo), esperar(tiempo) y devolver Derecha
```

```
si no, si localizacion = B y recién_aspiré = False entonces  
incrementar(tiempo), esperar(tiempo) y devolver Izquierda
```

c. Discuta posibles diseños de agentes para los casos en los que las cuadrículas limpias puedan ensuciarse y la geografía de medio sea desconocida. ¿Tiene sentido que el agente aprenda de su experiencia en estos casos? ¿Si es así, que debe aprender?

Considerando que el entorno presentado pareciera ser dinámico, estocástico y parcialmente observable, tiene sentido que aprenda de su experiencia.

Este aprendizaje debería ser sobre la geografía del medio, cuál es la ruta más rápida para recorrer esa geografía, determinar el tiempo óptimo para esperar entre las limpiezas.

7. Identifique la descripción REAS que define el entorno de trabajo para cada uno de los siguientes agentes:

a. Robot que juega al fútbol

Rendimiento: cantidad de goles, cantidad de partidos ganados, cantidad de goles evitados

Entorno: Cancha de futbol, jugadores, pelota, arbitro, arco

Actuadores: piernas y brazos robóticos, cabeza robotica

Sensores: cámara, sensores de proximidad, GPS

b. Agente para comprar libros de internet

Rendimiento: Cantidad de libros comprados, minimizar costo total (precio del libro y envio), minimizar tiempo de entrega

Entorno: Sitios web de librerías, páginas de reseñas de libros

Actuadores: Pantalla para mostrar resultados, relleno de formularios, servidor para realizar consultas HTTPS

Sensores: Analizadores sintácticos (parsers) de HTML y XML, formulario (para que el usuario especifique el libro que busca)

8. Para cada uno de los tipos de agente enumerados en el ejercicio anterior, caracterice el Entorno de acuerdo con las propiedades dadas en la sección 2.3 del libro determinístico vs. Estocástico, Observable vs. No-observable, etc.) y seleccione un diseño de agente adecuado.

En el caso del robot que juega al fútbol, su entorno de trabajo tendrá las siguientes propiedades:

- **Parcialmente observable:** El agente no podrá conocer el estado completo del entorno en cada momento : no podrá a través de sus sensores conocer la ubicación exacta de cada jugador ni tampoco conocer las intenciones o estrategia del equipo contrario.
- **Estocástico:** El siguiente estado del entorno no está completamente determinado por el estado actual y la acción ejecutada por el agente. Podría suceder que al patear una pelota esta se desvíe por múltiples factores
- **Secuencial:** las decisiones presentes del robot pueden afectar a decisiones futuras. Cada jugada realizada influye en la siguiente
- **Dinámico:** El entorno puede cambiar mientras el agente está deliberando. Tanto la pelota como los demás jugadores están en constante movimiento.
- **Continuo:** Las cantidad de percepciones y acciones distintas no son finitas ni discretas : posición de los jugadores y la pelota, velocidad, trayectoria de un pase, etc.
- **Multiagente competitivo:** El robot no está solo en el campo. El comportamiento de los demás jugadores está descrito por la maximización de una medida de rendimiento (por ejemplo, cantidad de goles anotados). Al mismo tiempo, si los demás jugadores maximizan su medida de rendimiento, el rendimiento del robot que juega al fútbol se ve disminuido

Este robot será un **agente que aprende**. Este diseño es el que mejor le permitirá desenvolverse en su entorno y elegir siempre la secuencia de acciones más correcta para alcanzar sus objetivos.

Este diseño consiste en incluir 4 componentes al programa del agente:

- Elemento de aprendizaje
- Elemento de actuación
- Crítica
- Generador de problemas

Ya que cada partido que jugará el robot será distinto al anterior, junto con rivales distintos que constantemente tomarán decisiones diferentes, cada nuevo partido se vuelve un entorno nuevo y desconocido. Entonces, este tipo de diseño se vuelve más útil que si sólo utilizase un conocimiento inicial. Le permite al agente operar en este entorno que desconoce e ir aprendiendo sobre sus rivales por ejemplo con el transcurso del partido.

Si por ejemplo el robot intentó hacer un gol al arquero pero su tiro fue atajado porque faltó potencia, el elemento de Crítica le proporcionará al elemento de aprendizaje cómo debe modificar el tiro en futuras oportunidades para mejorar sus resultados a futuro. Además, el componente generador de problemas le permitirá al agente tomar acciones que lo lleven a experiencias nuevas e informativas. Por ejemplo, en lugar de intentar dar un pase a un compañero, podría tomar la decisión de patear al arco desde una mayor distancia y que esto lleve a descubrir acciones mejores a largo plazo.

Por otro lado, el entorno de trabajo del agente para comprar libros por internet tiene las siguientes propiedades:

- **Parcialmente observable:** El agente no conoce el estado completo del entorno en todo momento. Ya que por ejemplo, no conoce el stock total de la librería o no conoce el día y horario en que se activan las ofertas
- **Estocástico:** El estado del medio no está completamente determinado por el estado actual y la acción ejecutada por el agente. Por ejemplo, al momento de añadir un libro al carrito puede que el libro ya no tenga stock o también las páginas web pueden caerse (errores 400 o 500) o cambiar la estructura del HTML sin aviso
- **Secuencial:** La compra de un libro implica una serie de pasos dependientes entre sí. Por ejemplo, la acción de pagar un libro requiere que previamente se lo haya añadido al carrito de compras
- **Dinámico:** El entorno puede verse modificado mientras el agente está “deliberando”, por ejemplo la cantidad de stock podría disminuir.

- **Discreto:** Hay un número finito de libros, enlaces en los que hacer clic, precios (percepciones) y acciones definidas (buscar, comprar, descartar)
- **Multiagente:** El agente compite con otros agentes (humanos por ejemplo) en la compra de libros

En este caso, este agente será un **agente basado en utilidad**. Ya que no sólo importa que el agente compre un libro, sino comprarlo bajo las mejores condiciones. Esto crea objetivos conflictivos, por ejemplo: ¿Es mejor un libro más barato pero con envío lento? ¿O un libro un poco más caro pero con stock garantizado y envío rápido?. Por este motivo, el agente basado en utilidad es capaz de elegir un camino cuando más de una secuencia de acciones lo llevan a su meta. Evalúa la probabilidad de que una secuencia sea más útil que otras y selecciona la mejor.